ESL Figure 2.1–2.4

Linear Regression 與 k-Nearest Neighbors

組員： 陳竣典 麥嘉祐 蔡旻宏

模擬資料生成方式

每一類先產生 10 個 Gaussian centers

BLUE：

$$m_k \sim N\left(\begin{bmatrix}1\\0\end{bmatrix}, I\right)$$

ORANGE：

$$m_k \sim N\left(\begin{bmatrix}0\\1\end{bmatrix}, I\right)$$

再由中心產生資料點

每產生一筆資料：

1. 從該類的 10 個中心中隨機選一個 m_k
2. 由

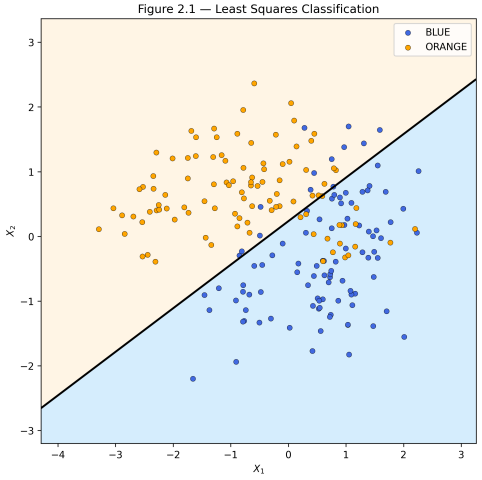
$$X \sim N\left(m_k, \frac{I}{5}\right)$$

產生資料點

Training data：

$$100\,\mathrm{BLUE} + 100\,\mathrm{ORANGE} = \boxed{200}$$

Figure 2.1：Least Squares Classification



設定

$$\text{BLUE} = 0, \qquad \text{ORANGE} = 1$$

線性迴歸模型：

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$$

分類 threshold：

$$\boxed{0.5}$$

$$\hat{Y} > 0.5 \Rightarrow \text{ORANGE}$$

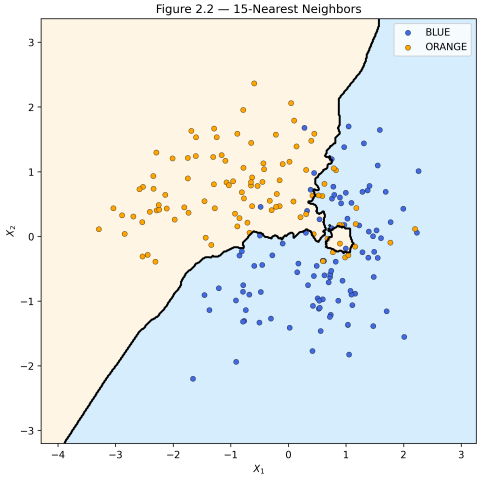
$$\hat{Y} \leq 0.5 \Rightarrow \text{BLUE}$$

Decision boundary 為

$$\boxed{\hat{Y} = 0.5}$$

因為模型是線性的，所以分界線是直線。

Figure 2.2：15-Nearest Neighbors



超參數

$$\boxed{k = 15}, \qquad \boxed{N = 200}$$

對平面上的一個位置 x：

1. 從 200 個 training points 找最近的 15 個
2. 計算 BLUE 與 ORANGE 的數量
3. 用多數決決定分類

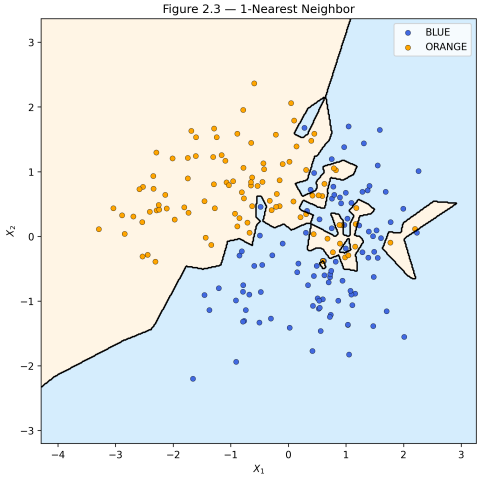
例如：

$$8\,\text{ORANGE} + 7\,\text{BLUE}$$

則預測為 ORANGE。

對整個平面的每個位置做相同判斷，分類結果改變的交界處就是 decision boundary。

Figure 2.3：1-Nearest Neighbor



超參數

$$\boxed{k = 1}$$

對每一個位置：

1. 找距離最近的一個 training point
2. 最近點是 BLUE，就預測 BLUE
3. 最近點是 ORANGE，就預測 ORANGE

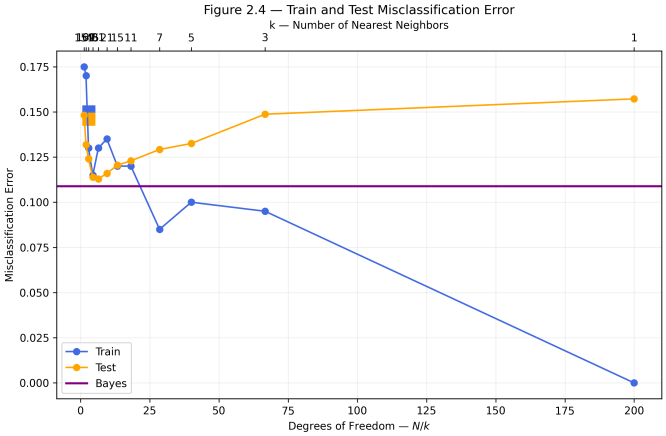
與 $k = 15$ 相比：

$$k \downarrow \Rightarrow \text{complexity} \uparrow$$

$$k \uparrow \Rightarrow \text{boundary smoother}$$

$k = 1$ 對單一 training point 很敏感。

Figure 2.4：Training Error 與 Test Error



資料量

$$N = 200, \qquad N_{\text{test}} = 10000$$

超參數

測試多個不同的 k。

模型複雜度

$$\boxed{\frac{N}{k}}$$

例如 $k = 1$：

$$\frac{200}{1} = 200$$

因此 k 越小，模型越複雜：

$$k \downarrow \Rightarrow \text{complexity} \uparrow$$

Training error 可能下降，但 test error 不一定下降；k 太小時可能 overfitting。

Figure 2.1–2.4 設定比較

Figure	方法	超參數	運作方式
2.1	Least Squares	Threshold $= 0.5$	線性預測值與 0.5 比較
2.2	k-NN	$k = 15$	最近 15 個 training points 多數決
2.3	k-NN	$k = 1$	使用最近的一個 training point
2.4	k-NN	不同的 k	比較 training error 與 test error

$k \downarrow \Rightarrow$ complexity $\uparrow$ $\qquad$ $k \uparrow \Rightarrow$ smoother boundary